



UNIVERSIDADE FEDERAL DO AMAZONAS
FACULDADE DE TECNOLOGIA
PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

REPAIRING QUANTIZED NEURAL NETWORKS VIA SMT THROUGH
SELECTIVE NEURON OPTIMIZATION

João Victor Lima de Souza

Dissertação de Mestrado apresentada ao
Programa de Pós-Graduação em Engenharia
Elétrica, PPGEE, da Universidade Federal
do Amazonas, como parte dos requisitos
necessários à obtenção do título de Mestre
em Engenharia Elétrica.

Orientador: Lucas Cordeiro

Manaus
Março de 2024



Ministério da Educação
Universidade Federal do Amazonas
Coordenação do Programa de Pós-Graduação em Engenharia Elétrica

FOLHA DE APROVAÇÃO

Poder Executivo Ministério da Educação
Universidade Federal do Amazonas
Faculdade de Tecnologia
Programa de Pós-graduação em Engenharia Elétrica

ANTONIO MARCOS DA COSTA PEREIRA

CLASSIFICAÇÃO AUTOMÁTICA DE MODULAÇÕES EM RECEPTORES ÓPTICOS COERENTES FLEXÍVEIS

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal do Amazonas, como requisito parcial para obtenção do título de Mestre em Engenharia Elétrica na área de concentração Controle e Automação de Sistemas.

Aprovada em 15 de março de 2024.

Documento assinado eletronicamente por:
Prof. Dr. Waldir Sabino da Silva Júnior Presidente
Prof. Dr. Celso Barbosa Carvalho (Membro Titular 2 - Interno)
Prof. Dr. Alexandre Coutinho Matheus (Membro Titular 1 - Externo)

Manaus, 11 de junho de 2024.



Documento assinado eletronicamente por **Waldir Sabino da Silva Júnior, Professor do Magistério Superior**, em 11/06/2024, às 09:02, conforme horário oficial de Manaus, com fundamento no art. 6º, § 1º, do [Decreto nº 8.539, de 8 de outubro de 2015](#).



Documento assinado eletronicamente por **Alexandre Coutinho Mateus, Usuário Externo**, em 11/06/2024, às 09:06, conforme horário oficial de Manaus, com fundamento no art. 6º, § 1º, do [Decreto nº 8.539, de 8 de outubro de 2015](#).



Documento assinado eletronicamente por **Celso Barbosa Carvalho, Professor do Magistério Superior**, em 11/06/2024, às 15:27, conforme horário oficial de Manaus, com fundamento no art. 6º, § 1º, do [Decreto nº 8.539, de 8 de outubro de 2015](#).



A autenticidade deste documento pode ser conferida no site https://sei.ufam.edu.br/sei/controlador_externo.php?acao=documento_conferir&id_orgao_acesso_externo=0, informando o código verificador **2088836** e o código CRC **9C9BEB4A**.

Av. Octávio Hamilton Botelho Mourão - Bairro Coroado 1 Campus Universitário Senador Arthur Virgílio Filho,
Setor Norte - Telefone: (92) 3305-1181
CEP 69080-900 Manaus/AM - mestrado_engelettrica@ufam.edu.br

Referência: Processo nº 23105.011910/2024-21

SEI nº 2088836

Criado por 62136828215, versão 3 por 62136828215 em 11/06/2024 08:47:49.

Ficha Catalográfica

Ficha catalográfica elaborada automaticamente de acordo com os dados fornecidos pelo(a) autor(a).

P436c Pereira, Antonio Marcos da Costa
Classificação Automática de Modulações em Receptores Ópticos
Coerentes Flexíveis / Antonio Marcos da Costa Pereira . 2024
108 f.: il. color; 31 cm.

Orientador: Waldir Sabino da Silva Júnior
Coorientador: André Luiz Aguiar da Costa
Dissertação (Mestrado em Engenharia Elétrica) - Universidade
Federal do Amazonas.

1. Classificação Automática de Modulação. 2. Redes Ópticas. 3.
Random Forest. 4. Perceptron Multicamada. I. Silva Júnior, Waldir
Sabino da. II. Universidade Federal do Amazonas III. Título

*Gostaria de expressar minha
gratidão...*

Agradecimentos

Expresso minha profunda gratidão...

Resumo da Dissertação apresentada à UFAM como parte dos requisitos necessários para a obtenção do grau de Mestre em Engenharia Elétrica

REPAIRING QUANTIZED NEURAL NETWORKS VIA SMT THROUGH
SELECTIVE NEURON OPTIMIZATION

João Victor Lima de Souza

Orientador: Lucas Cordeiro

Programa: Pós-Graduação em Engenharia Elétrica

Palavras-chave: Classificação Automática de Modulação, Redes Ópticas, *Random Forest*, *Perceptron* Multicamada.

Abstract of Dissertation presented to UFAM as a partial fulfillment of the requirements for the degree of Master in Electrical Engineering

REPAIRING QUANTIZED NEURAL NETWORKS VIA SMT THROUGH
SELECTIVE NEURON OPTIMIZATION

João Victor Lima de Souza

Advisor: Lucas Cordeiro

Department: Postgraduate in Electrical Engineering

Keywords: Automatic Modulation Classification, Optical Networks, Random Forest, Multilayer Perceptron.

Sumário

1	Introdução	1
1.1	Dissertation Objectives	2
1.1.1	General Objective	2
1.1.2	Objetivos específicos	2
1.2	Justificativa	3
1.3	Organização do trabalho	3
2	Fundamentos Teóricos	5
2.1	Network Repair	5
3	Metodologia	7
4	Related Works	8
4.1	Neural Network Verification is a Programming Language Challenge .	8
	Referências Bibliográficas	9
A	Artigos Publicados	11

Lista de Figuras

Lista de Tabelas

Capítulo 1

Introdução

From the first AI models such as Perceptron, which was proposed in 1958 [1], to the current state-of-the-art models like GPT-4 [2], AI has become a transformative force across various sectors. It's employed in healthcare for diagnostics such as Parkinson disease detection [3], in autonomous vehicles for safety features through the usage of Convolutional Neural Networks (CNNs) to detect driver distraction in real-time [4], and in finance for fraud detection by analyzing transaction patterns using advanced machine learning algorithms [5]. These examples illustrate the profound impact of AI on our daily lives, enhancing efficiency, safety, and decision-making processes.

These state-of-the-art models, however, are often too large and complex to be deployed on devices with limited resources, such as smartphones and IoT devices. The computational demands of these models can lead to significant latency and energy consumption, making them impractical for real-time applications in resource-constrained environments.

To address these challenges, quantization techniques are commonly employed to reduce the size of AI models [6]. Quantization involves reducing the precision of the model's weights and activations, which can lead to a significant reduction in memory usage and computational requirements. However, this process often results in a trade-off between model size and accuracy, as lower precision can degrade the performance of the model [7].

1.1 Dissertation Objectives

1.1.1 General Objective

The growing ubiquity of Artificial Intelligence (AI) is often limited by the computational demands of its models. Complex architectures like Deep Neural Networks (DNNs) and Convolutional Networks (CNNs) are particularly resource-intensive, hindering their deployment on devices with limited resources, such as smartphones and IoT hardware. While quantization is a common technique to reduce model size, it frequently leads to a trade-off in the form of reduced accuracy and performance. This dissertation introduces a novel approach that leverages Satisfiability Modulo Theories (SMT) solvers to mitigate this accuracy loss. We propose a framework where SMT solvers are used to systematically search for optimal quantization parameters. The primary objective is to enhance the quantization process, enabling the deployment of efficient and accurate AI models in resource-constrained environments.

1.1.2 Objetivos específicos

- Investigar e analisar o impacto da quantização de modelos de alto custo;
- Encontrar uma forma de encontrar parametros quantizados que tem maior impacto na acurácia do modelo;
- Desenvolver um *framework* que utilize solvers SMT para encontrar os parâmetros de quantização ideais, minimizando a perda de acurácia;
- Validar a eficácia do *framework* proposto em diferentes modelos de aprendizado de máquina e conjuntos de dados, demonstrando sua aplicabilidade e eficiência;
- Comparar o desempenho do *framework* com outras técnicas de quantização existentes, destacando suas vantagens e inovações;

1.2 Justificativa

The quantization of AI models is commonly used as a method to reduce and embed large models into limited resource devices. However, there is a trade-off between portability and accuracy that is inherent from change of representing the float-point as a fixed-point in the network nodes.

1.3 Organização do trabalho

A organização deste trabalho é observada conforme a estrutura a seguir:

- No Capítulo X, são revisados os conceitos fundamentais utilizados nesta dissertação. Englobando conceitos sobre os algoritmos de aprendizado de máquina e treinamento de modelos. A seguir, são abordados os conceitos-chave que implicam na complexidade e motivações para o uso de aprendizado de máquina no contexto de comunicações ópticas.
- No Capítulo Y, é apresentado o detalhamento sobre a metodologia utilizada para o desenvolvimento do *framework* de simulação da comunicação óptica. Abordando a simulação da transmissão, validação dos sinais recebidos e geração de uma base de dados rotulada.

Notas

O paper [8] foi o primeiro a usar state-of-art SMT solvers to encode problemas de verificação. O trabalho foi escrito em 2012. A motivação deste trabalho foi a ausência de ferramentas para verificação de redes neurais de forma automatizada como forma de garantir a confiabilidade dos modelos.

A técnica deles foi definida Counter-Example Triggered ABstraction-Refinement (CETAR).

"it by solving a satisfiability problem in Quantifier Free Linear Arithmetic over Reals (QF LRA in [7]) using the solver HYSAT [12]."

É checado "Global safety" e "Local safety".

we introduced global safety, i.e., checking that the response of the MLP ranges within a stated interval for all acceptable inputs, whereas in [21] we introduced local safety, i.e., checking that the response of the MLP is “close to” some training label as long as the input is “close to” the corresponding training input pattern.

Verifying Quantized Neural Networks using SMT-Based Model Checking

The approaches for ANN verification may be divided into three groups: optimization [34, 48, 84, 93], reachability [49, 54, 62, 92, 96, 100, 100], and satisfiability [47, 51, 61, 75].

// Ler sobre as competições de verificação de redes neurais. Brix, C., Müller, M.N., Bak, S., Johnson, T.T., Liu, C.: First three years of the international verification of neural networks competition (vnn-comp). International Journal on Software Tools for Technology Transfer 25(3), 329–339 (2023)

Brix, C., Bak, S., Johnson, T.T., Wu, H.: The fifth international verification of neural networks competition (vnn-comp 2024): Summary and results (2024), <https://arxiv.org/abs/2412.19985>

The verification can be divided into three properties: Geometric, Huper properties and Domain-sopecific properties.

// Languages lack the expressiveness to encode the properties of neural networks.

Capítulo 2

Fundamentos Teóricos

This is equivalence problem between $f()$ and $g()$, where f is the original function and g is the quantized function.

2.1 Network Repair

Like said before, QNN are widely employed in human-activity. However, the quantization process can lead to a significant loss of accuracy. To address this issue, researchers have explored various techniques to repair quantized neural networks (QNNs).

Repair NN have two main objectives: fix defects found in Neural Networks. It can be classified into three categories: retraining/fine-tuning, direct weight modification, and architecture extension [9].

The equivalence problem is a fundamental challenge in the field of neural Network Repair. It shows that the equivalence problem can be reduced to a Satisfiability problem [10].

This approach is not exclusive to QNNs.

- AIREPAIR: A Repair Platform for Neural Networks

Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks?

- This paper does not deal with quantized neural network - Deep Neural Networks (DNN) - It has been discovered that DNN can be disturbed even by the slightest perturbation - Verifying DNN is a difficult problem. They are large, non-linear, and non convex. - It's a NP-COMPLETE problem. - LP Solvers and SMT

solvers can be employed to verify DNN but until now have only be used to verify small Models. - Activation function are a problem because they are non linear, thus the papers focus only in Relu - It found out that some of RELU during search can be ignored.

Contribution - Reluplex presents itself as a SMT solver for a theory of real time arithmetic with ReLu constrains

Capítulo 3

Metodologia

XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX
XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX
XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX XXXX
XXXX XXXX XXXX XXXX.

Capítulo 4

Related Works

- Neural Network Verification is a Programming Language challenge

4.1 Neural Network Verification is a Programming Language Challenge

In this section, we will discuss the paper [11] which shows that network verification is in fact a programming challenge instead of a mathematical one.

The most accurate verifiers fail to reach full robustness. Szegedy, C., Zaremba, W., Sutskever, I., Bruna, J., Erhan, D., Goodfellow, I., Fergus, R.: Intriguing properties of neural networks (2014)

//Ler sobre as competições de verificação de redes neurais.

- Brix, C., Müller, M.N., Bak, S., Johnson, T.T., Liu, C.: First three years of the international verification of neural networks competition (vnn-comp). International Journal on Software Tools for Technology Transfer 25(3), 329–339 (2023)

- Brix, C., Bak, S., Johnson, T.T., Wu, H.: The fifth international verification of neural networks competition (vnn-comp 2024): Summary and results (2024), <https://arxiv.org/abs/2412.19985>

The verification can be divided into three properties: Geometric, Hyper properties and Domain-specific properties.

Languages lack the expressiveness to encode the properties of neural networks.

Referências Bibliográficas

- [1] ROSENBLATT, F., “The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain”, *Psychological Review*, v. 65, n. 6, pp. 386–408, 1958. [1](#)
- [2] OPENAI, *GPT-4 Technical Report*, Tech. Rep. arXiv:2303.08774, OpenAI, mar 2023. [1](#)
- [3] LUO, Y., HUANG, Y., FANG, G., et al., “Efficient recognition of Parkinson’s disease mice on stepping characters with CNN”, *Scientific Reports*, v. 15, n. 1, pp. 2566, jan 2025. [1](#)
- [4] LEI, J., NI, Z., PENG, Z., et al., “An intelligent network framework for driver distraction monitoring based on RES-SE-CNN”, *Scientific Reports*, v. 15, 02 2025. [1](#)
- [5] ZHU, Y., WANG, X., LI, J., et al., “A novel fraud detection method based on machine learning”, *Journal of Financial Crime*, v. 31, n. 1, pp. 123–135, jan 2024. [1](#)
- [6] ZHU, Y., GUPTA, S., “Trained quantization for deep neural networks”, *arXiv preprint arXiv:1612.06170*, dec 2016. [1](#)
- [7] ZHOU, A., YAO, A., GUO, Y., et al., “Incremental network quantization: Towards lossless CNNs with low-precision weights”, *arXiv preprint arXiv:1702.03044*, feb 2017. [1](#)
- [8] PULINA, L., TACCHIELLA, A., “Challenging SMT solvers to verify neural networks”, *AI COMMUNICATIONS*, v. 25, pp. 117–135, 01 2012. [3](#)

- [9] SONG, X., SUN, Y., MUSTAFA, M. A., et al., “QNNRepair: Quantized Neural Network Repair”, *arXiv preprint arXiv:2306.13793*, 2023. [5](#)
- [10] ELEFThERIADIS, C., KEKATOS, N., KATSAROS, P., et al., “On Neural Network Equivalence Checking using SMT Solvers”, 2022. [5](#)
- [11] CORDEIRO, L. C., DAGGITT, M. L., GIRARD-SATABIN, J., et al., “Neural Network Verification is a Programming Language Challenge”, 2025. [8](#)

Apêndice A

Artigos Publicados

Neste apêndice, o artigo desenvolvido nesta dissertação é apresentado.